

# 随机抽样课堂笔记

himkkk

September 22, 2026

## Contents

|                            |   |
|----------------------------|---|
| 1. 简单随机抽样 .....            | 3 |
| 1.1. 定义 .....              | 3 |
| 1.2. 均值与方差 .....           | 3 |
| 1.2.1. 简单的应用：比例 .....      | 6 |
| 1.3. 样本量的确定 .....          | 6 |
| 1.3.1. 费用限制 .....          | 7 |
| 1.3.2. 精度要求 .....          | 7 |
| 1.3.2.1. 精度要求 1 .....      | 7 |
| 1.3.2.2. 精度要求 2 .....      | 7 |
| 1.3.2.3. 精度要求 3 .....      | 7 |
| 1.3.2.4. 精度要求 4 .....      | 8 |
| 1.4. 利用辅助信息：比估计和回归估计 ..... | 8 |

# 1. 简单随机抽样

## 1.1. 定义

### 定义 1.1

从 $N$ 个单元的总体中抽取 $n$ 个单元，共有 $C_N^n$ 种可能的样本，若每一个样本被抽中的概率相等，则称这种抽样方法为简单随机抽样(SRS, simple random sampling)

### 性质 1.2

从总体中逐个不放回的抽取单元，每次从尚未入样的单元中等概率的抽取一个，直到抽取 $n$ 个样本为止。这样的抽样是简单随机抽样。

我们可以分出两类简单随机抽样

1. **有放回随机抽样**：每次抽取的编号服从 $\{1, 2, 3, \dots, N\}$ 的均匀分布  
他的特点如下：

- 总体中的一个样本可能被多次选中
- 重复的单元没有提供额外的信息，浪费了抽样的机会

2. **不放回的简单随机抽样**：如上面的定义  
特点为：

- 抽样的单元不会重复
- 相同的抽样机会包含更多（相对于有放回）的信息。

## 1.2. 均值与方差

### 定理 1.3

如果 $\bar{Y}$ 是总体均值， $\bar{y}$ 是样本均值，则 $\mathbb{E}\bar{y} = \bar{Y}$

证：  $\bar{y}_k = \frac{1}{n} \sum_{i \in \Omega_k} Y_i$ , 故

$$\begin{aligned}
\mathbb{E}\bar{y} &= \sum_{k=1}^M \mathbb{P}(\Omega_k) \bar{y}_k \\
&= \sum_{k=1}^M \frac{1}{M} \frac{1}{n} \sum_{i \in \Omega_k} Y_i \\
&= \frac{1}{Mn} \sum_{i=1}^N \sum_{k: i \in \Omega_k} Y_i \\
&= \frac{1}{Mn} C_{N-1}^{n-1} N \bar{Y} \\
&= \bar{Y}
\end{aligned}$$

其中  $M = C_{N-1}^{n-1}$

□

#### 定理 1.4

在不放回简单随机抽样下，方差和均方误差为

$$\text{MSE}(\bar{y}) = \text{Var}(\bar{y}) = \frac{1-f}{n} S^2 = \left( \frac{1}{n} - \frac{1}{N} \right) S^2$$

其中， $f = \frac{n}{N}$  为抽样比， $1-f$  记作有限总体校正系数， $S$  为总体标准差。

证：

$$\text{Var}(\bar{y}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n} \text{Var}(Y_i)$$

(这一步并不严谨，没有说明独立性) 考虑单个样本单元的方差，

$$\text{Var}(Y_i) = \mathbb{E}\left((Y_i - \bar{Y})^2\right) = \frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^2 = \frac{N-1}{N} S^2$$

□

#### 备注 1.5

为了严谨的证明，我们采用以下方式。考虑随机变量  $a_i = 1_{Y_i \in \Omega_k}$  代表第  $i$  个样本是否被抽样到。

$$\begin{aligned}
\text{Var}(\bar{y}) &= \text{Var}\left(\sum_{i=1}^N Y_i a_i\right) \\
&= \frac{1}{n^2} \sum_{i,j} \text{Cov}(Y_i a_i, Y_j a_j) \\
&= \frac{1}{n^2} \left( \sum_{i=1}^N Y_i^2 \text{Var}(a_i) + \sum_{i \neq j} Y_i Y_j \text{Cov}(a_i, a_j) \right)
\end{aligned}$$

简单的组合数学告诉我们,  $\mathbb{E}a_i = \mathbb{P}a_i = \frac{C_{N-1}^{n-1}}{C_N^n} = \frac{n}{N}$ ,  $\mathbb{E}a_i^2 = \mathbb{P}a_i = \frac{n}{N}$  而

$$\mathbb{E}a_i a_j = \mathbb{P}a_i a_j = \frac{C_{N-2}^{n-2}}{C_N^n} = \frac{n(n-1)}{N(N-1)}$$

因此,

$$\text{Var}(a_i) = \mathbb{E}(a_i^2) - (\mathbb{E}a_i)^2 = \frac{n}{N} - \frac{n^2}{N^2}$$

$$\text{Cov}(a_i, a_j) = \mathbb{E}a_i a_j - \mathbb{E}a_i \mathbb{E}a_j = \frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^2$$

故

$$\begin{aligned}
\text{Var}(\bar{y}) &= \frac{1}{n^2} \left( \sum_{i=1}^N Y_i^2 \frac{Nn - n^2}{N^2} + \sum_{i \neq j} Y_i Y_j \left( \frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^2 \right) \right) \\
&= \frac{1}{n^2} \frac{n(N-n)}{N^2(N-1)} \left( (N-1) \sum_{i=1}^N Y_i^2 - \sum_{i \neq j} Y_i Y_j \right) \\
&= \frac{1}{n^2} \frac{n(N-n)}{N^2(N-1)} \left( N \sum_{i=1}^N Y_i^2 - \sum_{i,j} Y_i Y_j \right) \\
&= \frac{1}{n^2} \frac{n(N-n)}{N^2(N-1)} \left( N \sum_{i=1}^N Y_i^2 - N^2 \bar{Y}^2 \right) \\
&= \frac{1}{n^2} \frac{n(N-n)}{N(N-1)} \left( \sum_{i=1}^N Y_i^2 - N \bar{Y}^2 \right) \\
&= \frac{1}{n^2} \frac{n(N-n)}{N(N-1)} (N-1) S^2 \\
&= \left( \frac{1}{n} - \frac{1}{N} \right) S^2
\end{aligned}$$

### 定理 1.6

不放回的简单随机抽样样本方差是总体方差的无偏估计。

证：

$$\begin{aligned}
\mathbb{E}s^2 &= \mathbb{E} \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\
&= \frac{1}{n-1} \mathbb{E} \sum_{i=1}^n (y_i - \bar{Y} + \bar{Y} - \bar{y})^2 \\
&= \frac{1}{n-1} \left( \sum_{i=1}^n \mathbb{E}(y_i - \bar{Y}^2) + 2(\bar{Y} - \bar{y}) \sum_{i=1}^n \mathbb{E}(y_i - \bar{Y}) + n(\bar{Y} - \bar{y})^2 \right) \\
&= \frac{1}{n-1} \left( \sum_{i=1}^n \mathbb{E}(Y_i a_i - \bar{Y}^2) + n \text{Var}(\bar{y}) \right) \\
&= \frac{1}{n-1} \left( \frac{n(N-1)}{N} S^2 - \frac{N-n}{N} S^2 \right) \\
&= S^2
\end{aligned}$$

□

由于实际中的数据大多为轻尾的，我们可以认为大部分情况下大数定律依然成立。考虑方差的估计  $\widehat{\text{Var}}(\bar{y}) = s^2$ ，则我们有区间估计

### 定理 1.7

在不放回简单随机抽样下，当  $N, n$  足够大的时候， $\bar{y}$  具有正态性，进而有区间估计

$$\left[ \bar{y} - z_{1-\frac{\alpha}{2}} \sqrt{\widehat{\text{Var}}(\bar{y})}, \bar{y} + z_{1+\frac{\alpha}{2}} \sqrt{\widehat{\text{Var}}(\bar{y})} \right]$$

### 1.2.1. 简单的应用：比例

考虑被一个性质划分的总体及其上面的一个样本， $P$  来标记符合这个性质的比例，即

$$Y_i = \begin{cases} 1 & Y_i \in C \\ 0 & \text{otherwise} \end{cases}$$

$$P = \frac{1}{N} \sum_{i=1}^n Y_i$$

则根据上面的公式，我们有

$$p = \mathbb{E}\bar{y} = \mathbb{E}\bar{Y} = P$$

$$\text{Var}(\bar{y}) = \frac{1-f}{n} S^2 = \frac{1-f}{n} \frac{NP(1-P)}{N-1}$$

### 1.3. 样本量的确定

一般的抽样调查中，样本量越大那么调查的方差和 MSE 就会越小。但同样的，调查的成本会增加。确定样本量的因素主要考虑两点：

1. 实际的成本限制
2. 需要的精度要求

### 1.3.1. 费用限制

假设成本满足  $c = c_0 + nc_1$ , 在成本限制为  $C$  的情况下,  $n \leq \frac{C-c_0}{c_1}$

### 1.3.2. 精度要求

通常我们有四种精度描述

1. 估计量的方差不大于某个值  $\text{Var}(\hat{\theta}) \leq V_0$
2. 估计量的变异系数不超过某个值  $\frac{\sqrt{\text{Var}(\hat{\theta})}}{\theta} \leq C_0$
3. 在  $1 - \alpha$  的置信度下, 估计量的绝对误差小于  $d$ , 即  $\mathbb{P}(|\hat{\theta} - \theta| \leq d) \geq 1 - \alpha$
4. 在  $1 - \alpha$  的置信度下, 估计量的相对误差小于  $d$ , 即  $\mathbb{P}\left(\left|\frac{\hat{\theta} - \theta}{\theta}\right| \leq d\right) \geq 1 - \alpha$

#### 1.3.2.1. 精度要求 1

$$\left(\frac{1}{n} - \frac{1}{N}\right) S^2 \leq V_0 \Leftrightarrow n \geq \frac{n_0}{1 + \frac{n_0}{N}}$$

其中,  $n_0 = \frac{S^2}{V_0}$

#### 1.3.2.2. 精度要求 2

$$\frac{\sqrt{\text{Var}(\bar{y})}}{\bar{Y}} \leq C_0 \Leftrightarrow \text{Var}(\bar{y}) \leq C_0^2 \bar{Y}^2$$

, 有次化归为 1 的情形, 故

$$n \geq \frac{n_0}{1 + \frac{n_0}{N}}$$

其中  $n_0 = \frac{S^2}{C_0^2 \bar{Y}^2}$

#### 1.3.2.3. 精度要求 3

考虑估计量  $\bar{Y}$ , 根据  $\bar{Y}$  的正态性,  $\frac{|\hat{Y} - \bar{Y}|}{\sqrt{\text{Var}(\hat{Y})}} \rightsquigarrow N(0, 1)$  故该条件等价于

$$\frac{d}{\sqrt{\text{Var}(\hat{Y})}} \geq z_{1-\frac{\alpha}{2}} \Leftrightarrow \text{Var}(\hat{Y}) \leq \left(\frac{d}{z_{1-\frac{\alpha}{2}}}\right)^2$$

化归为要求 2

### 1.3.2.4. 精度要求 4

$$\mathbb{P}\left(\left|\frac{\hat{\bar{Y}} - \bar{Y}}{\bar{Y}}\right| \leq d\right) \geq 1 - \alpha \Leftrightarrow \mathbb{P}\left(\left|\left(\hat{\bar{Y}} - \bar{Y}\right) \leq d\bar{Y}\right| \leq 1 - \alpha\right)$$

化归为要求 3

## 1.4. 利用辅助信息：比估计和回归估计

首先将上面的记号推广到多维情景

$$S_Z^2 = \frac{1}{N-1} \sum_{i=1}^n (Z_i - \bar{Z})(Z_i - \bar{Z})^\top$$

$$\mathbb{E}\bar{z} = \bar{Z}$$

$$\mathbb{E}s_z^2 = S_Z^2$$

$$\text{Var}(\bar{z}) = \frac{1-f}{n} S_Z^2$$

$$\text{Var}(\bar{Z})^{-\frac{1}{2}} (Z - \bar{Z}) \rightsquigarrow N(\mathbf{0}, \mathbf{I}) \Rightarrow (Z - \bar{Z}) \text{Var}(\bar{Z})^{-1} (Z - \bar{Z}) \rightsquigarrow \chi_n^2$$

同时, 我们有 delta 方法

$$g(\bar{z}) \sim g(\bar{Z}) + \frac{\partial g}{\partial z} \Big|_{z=\bar{Z}} (\bar{z} - \bar{Z})$$

故,

$$g(\bar{z}) \sim N\left(g(\bar{Z}), \left(\frac{\partial g}{\partial z} \Big|_{z=\bar{Z}}\right)^\top \text{Var}(\bar{z}) \frac{\partial g}{\partial z} \Big|_{z=\bar{Z}}\right)$$

对于二维统计量  $Z = (Y, X)^\top$ , 考虑比率统计量  $R = \frac{\bar{Y}}{\bar{X}}$ , 使用估计量  $\hat{R} = \frac{\bar{y}}{\bar{x}}$

### 定理 1.8

1.  $\mathbb{E}\hat{R} = R$
2.  $\text{Var}(\hat{R}) = \frac{1}{\bar{X}^2} \frac{1-f}{n} (s_y^2 - 2R s_{xy} + R^2 s_x^2)$

**证:** 考虑  $f(z) = \frac{y}{x}$ , 则  $\frac{\partial f}{\partial z} = \left(\frac{1}{x}, -\frac{y}{x^2}\right)^\top$  有 delta 方法,

$$f(\bar{z}) = f(\bar{Z}) + \left(\left(\frac{1}{x}, -\frac{y}{x^2}\right) \Big|_{z=\bar{Z}}\right)^\top (\bar{z} - \bar{Z})$$

因此,

$$f(\bar{z}) = \hat{R} \rightsquigarrow N\left(R, \frac{1}{\bar{X}^2} (\text{Var}(\bar{y}) - 2R \text{Cov}(\bar{x}, \bar{y}) + R^2 \text{Var}(\bar{x}))\right)$$

即

$$\mathbb{E}\hat{R} = R$$

$$\text{Var}(\hat{R}) = \frac{1}{\bar{X}^2} \frac{1-f}{n} (S_{yy}^2 - 2RS_{xy} + R^2 S_{xx}^2)$$

□

### 定理 1.9

方差的无偏估计为

$$\widehat{\text{Var}}(\hat{R}) = \frac{1}{\bar{x}^2} \frac{1-f}{n} (s_{yy}^2 - 2\hat{R}s_{xy} + \hat{R}^2 s_{xx}^2)$$

证： 先略

□