随机抽样课堂笔记

himkkk

September 29, 2026

Contents

1. 简单随机抽样 3
   1.1. 定义 3
   1.2. 均值与方差 3
      1.2.1. 简单的应用：比例 6
   1.3. 样本量的确定 6
      1.3.1. 费用限制 7
      1.3.2. 精度要求 7
         1.3.2.1. 精度要求 1 7
         1.3.2.2. 精度要求 2 7
         1.3.2.3. 精度要求 3 7
         1.3.2.4. 精度要求 4 8
   1.4. 利用辅助信息：比估计和回归估计 8
      1.4.1. 比估计 8
      1.4.2. 回归估计 10
   1.5. 子总体特征的估计 11
2. 分层抽样 12
   2.1. 均值和方差 12

1. 简单随机抽样

1.1. 定义

定义 1.1

从N 个单元的总体中抽取n 个单元，共有C_N^n 种可能的样本，若每一个样本被抽中的概率相等，则称这种抽样方法为简单随机抽样(SRS,simple random sampling)

性质 1.2

从总体中逐个不放回的抽取单元，每次从尚未入样的单元中等概率的抽取一个，直到抽取n 个样本为止。这样的抽样是简单随机抽样。

我们可以分出两类简单随机抽样

1. **有放回随机抽样**： 每次抽取的编号服从$\{1,2,3,...,N\}$ 的均匀分布
   他的特点如下：
   - 总体中的一个样本可能被多次选中
   - 重复的单元没有提供额外的信息，浪费了抽样的机会
2. **不放回的简单随机抽样**： 如上面的定义
   特点为：
   - 抽样的单元不会重复
   - 相同的抽样机会包含更多（相对于有放回）的信息。

1.2. 均值与方差

定理 1.3

如果$\overline{Y}$ 是总体均值，$\overline{y}$ 是样本均值，则$\mathbb{E}\overline{y}=\overline{Y}$

证： $\overline{y}_k=\frac{1}{n}\sum_{i\in\Omega_k}Y_i$,故

$$
\begin{aligned}
\mathbb{E}\overline{y} &= \sum_{k=1}^{M} \mathbb{P}(\Omega_k)\overline{y}_k \\
&= \sum_{k=1}^{M} \frac{1}{M}\frac{1}{n}\sum_{i\in\Omega_k} Y_i \\
&= \frac{1}{Mn}\sum_{i=1}^{N}\sum_{k:i\in\Omega_k} Y_i \\
&= \frac{1}{Mn} C_{N-1}^{n-1} N\overline{Y} \\
&= \overline{Y}
\end{aligned}
$$

其中$M = C_{N-1}^{n-1}$ □

定理 1.4

在不放回简单随机抽样下，方差和均方误差为

$$\mathrm{MSE}(\overline{y}) = \mathrm{Var}(\overline{y}) = \frac{1-f}{n}S^2 = \left(\frac{1}{n} - \frac{1}{N}\right)S^2$$

其中，$f = \frac{n}{N}$ 为抽样比，$1-f$ 记作有限总体校正系数，S 为总体标准差。

证：

$$\mathrm{Var}(\overline{y}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} Y_i\right) = \frac{1}{n}\ \mathrm{Var}(Y_i)$$

(这一步并不严谨，没有说明独立性) 考虑单个样本单元的方差，

$$\mathrm{Var}(Y_i) = \mathbb{E}\Big(\big(Y_i - \overline{Y}\big)^2\Big) = \frac{1}{N}\sum_{i=1}^{N}\big(Y_i - \overline{Y}\big)^2 = \frac{N-1}{N}S^2$$

□

备注 1.5

为了严谨的证明，我们采用以下方式。考虑随机变量$a_i = 1_{Y_i\in\Omega_k}$ 代表第i 个样本是否被抽样到。

$$
\begin{aligned}
\mathrm{Var}(\overline{y}) &= \mathrm{Var}\left(\sum_{i=1}^{N} Y_i a_i\right) \\
&= \frac{1}{n^2}\sum_{i,j}\mathrm{Cov}\left(Y_i a_i, Y_j a_j\right) \\
&= \frac{1}{n^2}\left(\sum_{i=1}^{N} Y_i^2 \mathrm{Var}(a_i) + \sum_{i\neq j} Y_i Y_j \mathrm{Cov}\left(a_i, a_j\right)\right)
\end{aligned}
$$

简单的组合数学告诉我们，$\mathbb{E}a_i = \mathbb{P}a_i = \frac{C_{N-1}^{n-1}}{C_N^n} = \frac{n}{N}$,$\mathbb{E}a_i^2 = \mathbb{P}a_i = \frac{n}{N}$ 而

$$
\mathbb{E}a_i a_j = \mathbb{P}a_i a_j = \frac{C_{N-2}^{n-2}}{C_N^n} = \frac{n(n-1)}{N(N-1)}
$$

因此,

$$
\mathrm{Var}(a_i) = \mathbb{E}(a_i^2) - (\mathbb{E}a_i)^2 = \frac{n}{N} - \frac{n^2}{N^2}
$$

$$
\mathrm{Cov}\left(a_i, a_j\right) = \mathbb{E}a_i a_j - \mathbb{E}a_i \mathbb{E}a_j = \frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^2
$$

故

$$
\begin{aligned}
\mathrm{Var}(\overline{y}) &= \frac{1}{n^2}\left(\sum_{i=1}^{N} Y_i^2 \frac{Nn-n^2}{N^2} + \sum_{i\neq j} Y_i Y_j \left(\frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^2\right)\right) \\
&= \frac{1}{n^2}\frac{n(N-n)}{N^2(N-1)}\left((N-1)\sum_{i=1}^{N} Y_i^2 - \sum_{i\neq j} Y_i Y_j\right) \\
&= \frac{1}{n^2}\frac{n(N-n)}{N^2(N-1)}\left(N\sum_{i=1}^{N} Y_i^2 - \sum_{i,j} Y_i Y_j\right) \\
&= \frac{1}{n^2}\frac{n(N-n)}{N^2(N-1)}\left(N\sum_{i=1}^{N} Y_i^2 - N^2\overline{Y}^2\right) \\
&= \frac{1}{n^2}\frac{n(N-n)}{N(N-1)}\left(\sum_{i=1}^{N} Y_i^2 - N\overline{Y}^2\right) \\
&= \frac{1}{n^2}\frac{n(N-n)}{N(N-1)}(N-1)S^2 \\
&= \left(\frac{1}{n} - \frac{1}{N}\right)S^2
\end{aligned}
$$

定理 1.6

不放回的简单随机抽样样本方差是总体方差的无偏估计。

证：

$$
\begin{aligned}
\mathbb{E}s^2 &= \mathbb{E}\frac{1}{n-1}\sum_{i=1}^{n}\left(y_i-\overline{y}\right)^2 \\
&= \frac{1}{n-1}\mathbb{E}\sum_{i=1}^{n}\left(y_i-\overline{Y}+\overline{Y}-\overline{y}\right)^2 \\
&= \frac{1}{n-1}\left(\sum_{i=1}^{n}\mathbb{E}\left(y_i-\overline{Y}^2\right)+2\left(\overline{Y}-\overline{y}\right)\sum_{i=1}^{n}\mathbb{E}\left(y_i-\overline{Y}\right)+n\left(\overline{Y}-\overline{y}\right)^2\right) \\
&= \frac{1}{n-1}\left(\sum_{i=1}^{n}\mathbb{E}\left(Y_i a_i-\overline{Y}^2\right)+n\ \mathrm{Var}(\overline{y})\right) \\
&= \frac{1}{n-1}\left(\frac{n(N-1)}{N}S^2-\frac{N-n}{N}S^2\right) \\
&= S^2
\end{aligned}
$$

□

由于实际中的数据大多为轻尾的，我们可以认为大部分情况下大数定律依然成立。考虑方差的估计$\widehat{\mathrm{Var}}(\overline{y})=s^2$，则我们有区间估计

定理 1.7

在不放回简单随机抽样下，当N,n足够大的时候，$\overline{y}$具有正态性，进而有区间估计

$$
\left[\overline{y}-z_{1-\frac{\alpha}{2}}\sqrt{\widehat{\mathrm{Var}}(\overline{y})},\overline{y}+z_{1+\frac{\alpha}{2}}\sqrt{\widehat{\mathrm{Var}}(\overline{y})}\right]
$$

1.2.1. 简单的应用：比例

考虑被一个性质划分的总体及其上面的一个样本，P来标记符合这个性质的比例，即

$$
Y_i=\begin{cases}1 & Y_i\in C\\ 0 & \text{otherwise}\end{cases}
$$

$$
P=\frac{1}{N}\sum_{i=1}^{n}Y_i
$$

则根据上面的公式，我们有

$$
p=\mathbb{E}\overline{y}=\mathbb{E}\overline{Y}=P
$$

$$
\mathrm{Var}(\overline{y})=\frac{1-f}{n}S^2=\frac{1-f}{n}\frac{NP(1-P)}{N-1}
$$

1.3. 样本量的确定

一般的抽样调查中，样本量越大那么调查的方差和 MSE 就会越小。但同样的，调查的成本会增加。 确定样本量的因素主要考虑两点：

1. 实际的成本限制

2. 需要的精度要求

1.3.1. 费用限制

假设成本满足$c = c_0 + nc_1$,在成本限制为C 的情况下，$n \leq \frac{C-c_0}{c_1}$

1.3.2. 精度要求

通常我们有四种精度描述

1. 估计量的方差不大于某个值 $\mathrm{Var}\left(\hat{\theta}\right) \leq V_0$

2. 估计量的变异系数不超过某个值 $\frac{\sqrt{\mathrm{Var}\left(\hat{\theta}\right)}}{\theta} \leq C_0$

3. 在$1-\alpha$ 的置信度下，估计量的绝对误差小于d,即$\mathbb{P}\left(\left|\hat{\theta}-\theta\right| \leq d\right) \geq 1-\alpha$

4. 在$1-\alpha$ 的置信度下，估计量的相对误差小于d,即$\mathbb{P}\left(\left|\frac{\hat{\theta}-\theta}{\theta}\right| \leq d\right) \geq 1-\alpha$

1.3.2.1. 精度要求 1

$$\left(\frac{1}{n}-\frac{1}{N}\right)S^2 \leq V_0 \Leftrightarrow n \geq \frac{n_0}{1+\frac{n_0}{N}}$$

其中，$n_0 = \frac{S^2}{V_0}$

1.3.2.2. 精度要求 2

$$\frac{\sqrt{\mathrm{Var}(\overline{y})}}{\overline{Y}} \leq C_0 \Leftrightarrow \mathrm{Var}(\overline{y}) \leq C_0^2\overline{Y}^2$$

,有次化归为 1 的情形，故

$$n \geq \frac{n_0}{1+\frac{n_0}{N}}$$

其中$n_0 = \frac{S^2}{C_0^2\overline{Y}^2}$

1.3.2.3. 精度要求 3

考虑估计量$\overline{Y}$,根据$\overline{Y}$ 的正态性，$\frac{|\hat{\overline{Y}}-\overline{Y}|}{\sqrt{\left(\mathrm{Var}\left(\hat{\overline{Y}}\right)\right)}} \rightsquigarrow N(0,1)$ 故该条件等价于

$$\frac{d}{\sqrt{\left(\mathrm{Var}\left(\hat{\overline{Y}}\right)\right)}} \geq z_{1-\frac{\alpha}{2}} \Leftrightarrow \mathrm{Var}\left(\hat{\overline{Y}}\right) \leq \left(\frac{d}{z_{1-\frac{\alpha}{2}}}\right)^2$$

化归为要求 2

1.3.2.4. 精度要求 4

$$\mathbb{P}\left(\left|\frac{\hat{\overline{Y}}-\overline{Y}}{\overline{Y}}\right|\leq d\right)\geq 1-\alpha \Leftrightarrow \mathbb{P}(\left|\left(\hat{\overline{Y}}-\overline{Y}\right)\leq d\overline{Y}\right|\leq 1-\alpha$$

化归为要求 3

1.4. 利用辅助信息：比估计和回归估计

1.4.1. 比估计

首先将上面的记号推广到多维情景

$$S_{\boldsymbol{Z}}^2=\frac{1}{N-1}\sum_{i=1}^{n}\left(\boldsymbol{Z}_i-\overline{\boldsymbol{Z}}\right)\left(\boldsymbol{Z}_i-\overline{\boldsymbol{Z}}\right)^{\top}$$

$$\mathbb{E}\overline{\boldsymbol{z}}=\overline{\boldsymbol{Z}}$$

$$\mathbb{E}s_{\overline{\boldsymbol{z}}}^2=S_{\overline{\boldsymbol{Z}}}^2$$

$$\mathrm{Var}(\overline{\boldsymbol{z}})=\frac{1-f}{n}S_{\boldsymbol{Z}}^2$$

$$\mathrm{Var}\left(\overline{\boldsymbol{Z}}\right)^{-\frac{1}{2}}\left(\boldsymbol{Z}-\overline{\boldsymbol{Z}}\right)\rightsquigarrow N(\boldsymbol{0},\boldsymbol{I})\Rightarrow\left(\boldsymbol{Z}-\overline{\boldsymbol{Z}}\right)\mathrm{Var}\left(\overline{\boldsymbol{Z}}\right)^{-1}\left(\boldsymbol{Z}-\overline{\boldsymbol{Z}}\right)\rightsquigarrow \mathrm{X}_n^2$$

同时，我们有 delta 方法

$$g(\overline{\boldsymbol{z}})\sim g\left(\overline{\boldsymbol{Z}}\right)+\frac{\partial g}{\partial z}\mid_{z=\overline{\boldsymbol{Z}}}\left(\overline{\boldsymbol{z}}-\overline{\boldsymbol{Z}}\right)$$

故，

$$g(\overline{\boldsymbol{z}})\sim N\left(g\left(\overline{\boldsymbol{Z}}\right),\left(\frac{\partial g}{\partial z}\mid_{z=\overline{\boldsymbol{Z}}}\right)^{\top}\mathrm{Var}(\overline{\boldsymbol{z}})\frac{\partial g}{\partial z}\mid_{z=\overline{\boldsymbol{Z}}}\right)$$

对于二维统计量$\boldsymbol{Z}=(Y,X)^{\top}$,考虑比率统计量$R=\frac{\overline{Y}}{\overline{X}}$,使用估计量$\hat{R}=\frac{\overline{y}}{\overline{x}}$

> **定理 1.8**
>
> 1. $\mathbb{E}\hat{R}=R$
> 2. $\mathrm{Var}\left(\hat{R}\right)=\frac{1}{\overline{X}^2}\frac{1-f}{n}\left(s_y^2-2Rs_{xy}+R^2s_x^2\right)$

证： 考虑$f(z)=\frac{y}{x}$,则$\frac{\partial f}{\partial \boldsymbol{z}}=\left(\frac{1}{x},-\frac{y}{x^2}\right)^{\top}$ 有 delta 方法，

$$f(\overline{\boldsymbol{z}})=f\left(\overline{\boldsymbol{Z}}\right)+\left(\left(\frac{1}{x},-\frac{y}{x^2}\right)\mid_{\boldsymbol{z}=\overline{\boldsymbol{Z}}}\right)^{\top}\left(\overline{\boldsymbol{z}}-\overline{\boldsymbol{Z}}\right)$$

因此，

$$f(\overline{z})=\hat{R} \rightsquigarrow N\left(R, \frac{1}{\overline{X}^2}(\operatorname{Var}(\overline{y})-2R\ \operatorname{Cov}(\overline{x}, \overline{y})+R^2 \operatorname{Var}(\overline{x}))\right)$$

即

$$\mathbb{E}\hat{R}=R$$

$$\operatorname{Var}\left(\hat{R}\right)=\frac{1}{\overline{X}^2}\frac{1-f}{n}\left(S_{yy}^2-2RS_{xy}+R^2S_{xx}^2\right)$$

□

定理 1.9

方差的渐进无偏估计为

$$\widehat{\operatorname{Var}}\left(\hat{R}\right)=\frac{1}{\overline{x}^2}\frac{1-f}{n}\left(s_{yy}^2-2\hat{R}s_{xy}+\hat{R}^2s_{xx}^2\right)$$

证： 先略 □

因此，在已知$\overline{X}$ 的信息情况下，我们可以利用比估计来估计$\overline{Y}_R=\hat{R}\overline{X}$. 我们有如下性质

性质 1.10

1. $\mathbb{E}\left(\widehat{\overline{Y}_R}\right)=\overline{Y}$
2. $\operatorname{Var}\left(\widehat{\overline{Y}_R}\right)=\frac{1-f}{n}\left(S_{yy}^2-2RS_{xy}+R^2S_{xx}^2\right)$
3. $\widehat{\operatorname{Var}}\widehat{\overline{Y}_R}=\frac{1-f}{n}\left(s_{yy}^2-2\hat{R}s_{xy}+\hat{R}^2s_{xx}^2\right)$

如何判断与简单估计的更优性？考虑方差的差

$$\begin{aligned}\operatorname{Var}\left(\hat{\overline{Y}}\right)-\operatorname{Var}\left(\widehat{\overline{Y}_R}\right)&=\frac{1-f}{n}S_{yy}^2-\frac{1-f}{n}\left(S_{yy}^2-2RS_{xy}+R^2S_{xx}^2\right)\\&=\frac{1-f}{n}\left(2RS_{xy}-R^2S_{xx}^2\right)\end{aligned}$$

性质 1.11

当$2RS_{xy}-R^2S_{xx}^2\geq 0$时，比估计更优（方差更小），在实际应用中，通常比$R$ 为正，因此当

$$\rho>\frac{RS_{xx}}{2S_{yy}}$$

比估计更好，其中$\rho S_{xx}S_{yy}=S_{xy}$

1.4.2. 回归估计

回归估计不要求像比估计一样两个变量之间的正比例关系，回归估计可以考虑更一般的线性关系，并且可以利用更多的额外信息。在简单不放回随机抽样下，总体均值的回归估计为

$$\widehat{\overline{Y}_{lr}} = \overline{y} + \beta\left(\overline{X} - \overline{x}\right)$$

定理 1.12

在β 已知的情况下，我们有

1. $\mathbb{E}\left(\widehat{\overline{Y}_{lr}}\right) = \overline{Y}$
2. $\mathrm{Var}\left(\widehat{\overline{Y}_{lr}}\right) = \frac{1-f}{n}\left(S_{yy}^2 - 2\beta S_{xy} + \beta^2 S_{xx}^2\right)$

证：

$$\begin{aligned}
\mathbb{E}\left(\widehat{\overline{Y}_{lr}}\right) &= \mathbb{E}\left(\overline{y} + \beta\left(\overline{X} - \overline{x}\right)\right) \\
&= \mathbb{E}(\overline{y}) + \beta\mathbb{E}\left(\overline{X} - \overline{x}\right) \\
&= \overline{Y} + \beta \times 0 \\
&= \overline{Y}
\end{aligned}$$

$$\begin{aligned}
\mathrm{Var}\left(\widehat{\overline{Y}_{lr}}\right) &= \mathrm{Var}\left(\overline{y} + \beta\left(\overline{X} - \overline{x}\right)\right) \\
&= \mathrm{Var}(\overline{y} - \beta\overline{x}) \\
&= \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \beta x_i)\right) \\
&= \frac{1-f}{n}\ \mathrm{Var}(y_i - \beta x_i) \\
&= \frac{1-f}{n}\left(S_{yy}^2 - 2\beta S_{xy} + \beta^2 S_{xx}^2\right)
\end{aligned}$$

在这里我们用到了简单估计的方差公式。 □

如果β 未知（这也是大部分实际情况），我们需要MSE最小的估计 $\hat{\beta}$，又我们需要的统计量是近似无偏的，因此我们要$\hat{\beta}$ 最小化我的方差,即$\hat{\beta} = \frac{S_{xy}}{S_{xx}^2}$ 此时我们有

定理 1.13

1. $\mathbb{E}\left(\widehat{\overline{Y}_{lr}}\right) = \overline{Y}$
2. $\mathrm{Var}\left(\widehat{\overline{Y}_{lr}}\right) = \frac{1-f}{n}\left(S_{yy}^2 - 2\hat{\beta} S_{xy} + \hat{\beta}^2 S_{xx}^2\right) = \frac{1-f}{n} S_{yy}^2(1-\rho^2)$
3. $\widehat{\mathrm{Var}}\left(\widehat{\overline{Y}_{lr}}\right) = \frac{1-f}{n}\frac{n-1}{n-2} s_{yy}^2(1-\hat{\rho}^2)$

在这里因为残差的期望为 0，并且残差与数据独立，因此自由度为$n-2$ 故需要$\frac{1}{n-2}$的修正。

可以看出，回归估计总是比简单估计更优。

同样的，通过做差，也可以得到回归估计比比估计更优。

1.5. 子总体特征的估计

定义 1.14

总体按照属性进行划分称为子总体。

假定总体有N 个单元，指标为Y_i 若单元$i \in D$则， $X_i = 1$，否则为 0.

定义 1.15

子总体的规模定义为$N_D = \sum_{i=1}^{n} X_i$

子总体的总和为$Y_D = \sum_{i=1}^{N} y_i X_i$

子总体的均值为$\overline{Y}_D = \frac{Y_D}{N_D}$

子总体总和Y_D的估计

定理 1.16

定义$Z_i = Y_i X_i$ 则

1. $\hat{Y}_D = N\overline{z} = \frac{N}{n}\sum_{i=1}^{n} z_i$
2. $\widehat{\mathrm{Var}}\left(\hat{Y}_D\right) = N^2 \frac{1-f}{n} s_z^2$

子总体均值的估计，由于规模通常未知，我们做如下变换 $\widehat{\overline{Y}_D} = \frac{\sum_{i=1}^{n} z_i}{n_D} = \frac{\overline{z}}{\overline{x}}$ 因此可以使用比估计的方法去解决。

2. 分层抽样

当总体内部存在明显的分层结构时，简单随机抽样会导致某些子总体代表性不足，影响估计的精度。

2.1. 均值和方差

总体均值的估计量$\overline{Y} = \overline{y}_{st}$ 有这些性质：

定理 2.1

1. 无偏性：$\mathbb{E}(\overline{y}_{st}) = \sum_{h=1}^{L} W_h \mathbb{E}(\overline{y}_h) = \sum_{h=1}^{L} W_h \overline{Y}_h = \overline{Y}$
2. 方差: $\mathrm{Var}(\overline{y}_{st}) = \sum_{h=1}^{L} W_h \mathrm{Var}(\overline{y}_h) = \sum_{h=1}^{L} W_h^2 \frac{1-f_h}{n_h} S_h^2$
3. 无偏估计： $\widehat{\mathrm{Var}}(\hat{y}_{st}) = \sum_{h=1}^{L} W_h \mathrm{Var}(\overline{y}_h) = \sum_{h=1}^{L} W_h^2 \frac{1-f_h}{n_h} s_h^2$